Ex 1

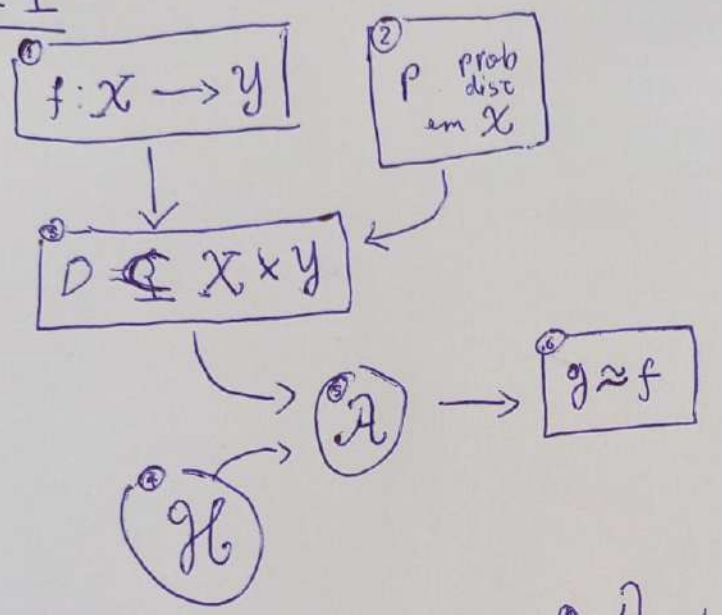

① Função desconhecida a qual desejamos aproximar.

② Distribuição P em $\mathcal{X}$ associada a observação dos dados $x_1, x_2, \dots, x_n \in \mathcal{X}$

③ Conjunto de dados / evidências $\mathcal{D} \subset \mathcal{X} \times \mathcal{Y}$ que atestam $f(x_i) = y_i$ para $(x_i, y_i) \in \mathcal{D}$.

④ Espaço de possíveis funções $g \in \mathcal{H}$ que ~~eventualmente~~ podem aproximar f.

⑤ $\mathcal{A}$ é um algoritmo tal que

$$\mathcal{A} : \mathcal{P}(\mathcal{X} \times \mathcal{Y}) \longrightarrow \mathcal{H}$$
$$\mathcal{D} \longmapsto g$$

i.e., $\mathcal{A}$ escolhe uma função $g \in \mathcal{H}$ com base nas evidências $\mathcal{D}$.

⑥ Final do processo que escolhe $g \in \mathcal{H}$ através de $\mathcal{A}$ com base em $\mathcal{D}$ para aproximar f.

$$\mathcal{H} \ni \mathcal{A}(\mathcal{D}) =: g \approx f.$$

<u>Diagrama</u> Ilustra o processo geral de "aprendizagem", i.e., método de aproximação utilizado em ML

Ex 2 Considere a <u>notação</u> do Ex 1: $f, \mathcal{X}, \mathcal{Y}, \mathcal{D}, P, \mathcal{A}, \mathcal{H}, g$.

- E_{in} é o <u>erro</u> médio associado a uma amostra; ie, dada uma função $\mathcal{L}$ de perda associada a $\mathcal{A}$,

$$E_{in}(\mathcal{D}) = E_{in} : \mathcal{H} \longrightarrow \mathbb{R}$$
$$g \longmapsto \frac{1}{|\mathcal{D}|} \sum_{(x,y)\in\mathcal{D}} \mathcal{L}(g(x), y).$$

- E_{out} é o <u>erro esperado</u> de toda ~~o~~ ~~uma~~ espaço amostral:

Seja $Z_g : \mathcal{X} \times \mathcal{Y} \longrightarrow \mathbb{R}$ uma variável aleatória de perda: $Z_g(x,y) = \mathcal{L}(g(x), y)$ de uma dada $g \in \mathcal{H}$. Então

$$E_{out} : \mathcal{H} \longrightarrow \mathbb{R}$$
$$g \longmapsto \mathbb{E}[Z_g].$$

Ex 3 $|E_{in} - E_{out}|$ mede o desempenho do algorítimo na base de dados $\mathcal{D} \subset \mathcal{X} \times \mathcal{Y}$. Tal quantia arbitra a capacidade de modelagem do nosso problema. Como E_{out} geralmente não é calculável, temos algumas ferramentas probabilísticas que possibilitam estimar tal quantia.

Ex 4 Seja $\varepsilon > 0$ uma taxa de erro tolerável. Seguindo um algorítimo $\mathcal{A}$, gostaríamos que nosso output $g \in \mathcal{H}$ não esteja $(\geq \varepsilon)$-distante da realidade, i.e., $|E_{in}(g) - E_{out}(g)|$ não deve ser maior que ε. A des. de Hoeffding expressa a probabilidade desse evento ocorrer em função dos dados amostrais $\mathcal{D} \subset \mathcal{X} \times \mathcal{Y}$:

$$(4.1) \qquad \mathbb{P}\left(|E_{in}(g) - E_{out}(g)| > \varepsilon\right) \leq 2\exp\left(-2\varepsilon^2 |\mathcal{D}|\right)$$

Logo: $\lim_{|\mathcal{D}| \to \infty} \mathbb{P}\left(E_{in}(g) - E_{out}(g)\right) = 0$. Portanto, (4.1) apresenta uma ~~estimativa~~ resposta para a pergunta:

"Is Learning feasible?"

Sim, caso se: (i) tenha-se dados o suficiente, (ii) $g \in \mathcal{H}$ for escolhida com um controle de complexidade, de modo que o erro amostral seja computável.

erro amostral seja computável. //

Ex 5 O fator multiplicativo M contabilizando M hipóteses aumenta a chance do erro de generalização, i.e., quanto maior o número de hipóteses, maior a chance de encontrar uma que se ajusta bem aos dados por acaso.

Ex 6 O "union-bound" é a realização da propriedade σ-aditiva de espaços de probabilidade $(\Omega, \Sigma, \mathbb{P})$, aplicada a eventos com várias possíveis hipóteses:

$$\mathbb{P}\left(|E_{in}(g) - E_{out}(g)| > \epsilon\right)$$

$$= \mathbb{P}\left(\bigcup_{h=1}^{M} \{|E_{in}(h_i) - E_{out}(h_i)| > \epsilon\}\right)$$

$$\overset{\sigma\text{-add.}}{\leq} \sum_{i=1}^{M} \underbrace{\mathbb{P}\left(|E_{in}(h_i) - E_{out}(h_i)| > \epsilon\right)}_{\leq 2\exp(-2\epsilon^2|\mathcal{D}|)}$$

$$= M \cdot 2\exp(-2\epsilon^2|\mathcal{D}|).$$

//

Ex 7 Uma dicotomia é uma partição das hipóteses em dois subconjuntos disjuntos: (A, B) é uma partição de $\mathcal{H}$ se $A \cup B = \mathcal{D}$ e $A \cap B = \emptyset$.

//

[illegible] em dois subconjuntos disjuntos: (A, B) é uma partição de $\mathcal{H}$ se $A \cup B = \mathcal{H}$ e $A \cap B = \emptyset$.

Ex 8 A <u>growth function</u> conta o número de dicotomias com N pontos:

$$m_{\mathcal{H}} : \mathbb{N} \longrightarrow \mathbb{N}$$
$$N \longmapsto \max_{x_1, x_2 \cdots x_N \in \mathcal{X}} |\mathcal{H}(x_1, \cdots, x_N)|$$

Um dado $k \in \mathbb{N}$ é um <u>break point</u> se $\mathcal{H}$ não puder ser particionado em dicotomias.

Quando $\mathcal{H}$ admite um break-point, a função $m_{\mathcal{H}}$ é necessariamente polinomial. Decorre disso que a desigualdade de Hoeffding com um espaço de M hipóteses pode ser adaptada com $m_{\mathcal{H}}$:

$$\mathbb{P}\left(|E_{in}(g) - E_{out}(g)| > \varepsilon\right)$$

$$\leq 4 \cdot m_{\mathcal{H}}(2|\mathcal{D}|) \exp\left(-\frac{1}{8}\varepsilon^2 |\mathcal{D}|\right).$$

Mostrando que métrica de desempenho $|E_{in} - E_{out}|$ pode ser estimada não só em termos da quantidade de dados, como também do espaço de hipóteses.

//

Ex 9 O processo se da no contexto em que $\mathcal{H}$ é infinito, mas as hipóteses podem ser agrupadas em dicotomias, onde o union bound é aplicado nesses agrupamentos. O novo bound ja foi escrito ~~no~~ exercício 8 na eq. (8.1).

Ex 10 Seja $\delta := 4\, m_{\mathcal{H}}(2|\mathcal{V}|)\, e^{-\frac{1}{8}\varepsilon^2 |\mathcal{V}|}$.

Isolando ε em função de δ, obtemos

$$\varepsilon = \sqrt{\frac{8}{|\mathcal{V}|} \ln \frac{4\, m_{\mathcal{H}}(2|\mathcal{V}|)}{\delta}}.$$

$$\mathbb{P}(|E_{in} - E_{out}| > \varepsilon) \leq \delta$$

$$\iff \mathbb{P}(|E_{in} - E_{out}| \leq \varepsilon) \geq 1 - \delta.$$

Ou seja, com probabilidade maior que $1-\delta$, temos

$$|E_{in}(g) - E_{out}(g)| \leq \underbrace{\sqrt{\frac{8}{|\mathcal{H}|} \ln \frac{4 m_{\mathcal{H}}(2|\mathcal{H}|)}{\delta}}}_{\varepsilon}.$$

//

Ex 11 Isso porque a taxa de erro do modelo pode ainda ser muito elevada e não nos providenciar uma aproximação boa da função objetiva. Garantir que $|E_{in}(h) - E_{out}(h)| \leq \varepsilon$ só nos informa que a performance de h é semelhante na amostra ao do espaço amostral total.

Ex 12 $d_{vc}(\mathcal{H})$ é o maior natural $N \in \mathbb{N}$ tal que

$$m_{\mathcal{H}}(N) = 2^N.$$

indicando a maior quantidade de pontos o qual $\mathcal{H}$ pode se particionar.

Ex 13 Dada uma tolerância $\varepsilon > 0$, δ é uma margem de probabilidade em função de $N := |\mathcal{D}|$. Como d_{vc} é uma medida de complexidade, a inequação apresentada estabelece

uma condição necessária sobre o número do tamanho da amostra N e a taxa de erro ε devem satisfazer para garantir uma boa capacidade de aprendizado.

Ex 14 O viés mede a diferença entre a esperança do modelo em relação ao valor verdadeiro, e idealmente procura-se minimizá-lo.

Já a variância é uma métrica de robustez do modelo a variações dos inputs, que tem uma relação inversa com o viés, i.e.,

$$\begin{cases} (\Downarrow \text{viés}) \Leftrightarrow (\Uparrow \text{variância}) \\ (\Uparrow \text{viés}) \Leftrightarrow (\Downarrow \text{variância}) \end{cases}$$

① "Bias - Variance Analysis"
busca encontrar justamente um equilíbrio entre as duas métricas que reduzam o erro total ainda assim.

Ex 15

- VC Analysis Ferramentas para mensurar o poder preditivo de uma modelo, e estabelecer relações entre número de dados e erro de tolerância.

- Bias - Var Ferramentas para categorizar a natureza dos resíduos de um modelo, relacionando sua complexidade e robustez em relação aos dados.